



PROYECTO BD

Daniel Casas Yuste



ÍNDICE


INTRODUCCIÓN	3
ARQUITECTURA DEL SISTEMA	4
INGESTA DE DATOS – APACHE NIFI	5
COLA DE MENSAJES – APACHE KAFKA	6
PROCESAMIENTO – APACHE SPARK	7
ALMACENAMIENTO – POSTGRESQL	8
VISUALIZACIÓN – GRAFANA	9

INTRODUCCIÓN

El presente proyecto consiste en el desarrollo de un pipeline de Big Data completo para la monitorización en tiempo real de las estaciones de bicicletas Valenbisi de la ciudad de Valencia. El sistema captura datos automáticamente desde una API pública, los procesa y los visualiza en un dashboard interactivo.

La API utilizada es <https://api.citybik.es/v2/networks/valenbisi>, que proporciona datos en tiempo real de las 277 estaciones de Valenbisi sin necesidad de registro ni autenticación. Por cada estación se obtienen datos como el número de bicis disponibles, los huecos libres y la marca de tiempo de la última actualización.


El objetivo principal es demostrar el uso integrado de herramientas del ecosistema Big Data para construir un flujo de datos funcional de principio a fin.



ARQUITECTURA DEL SISTEMA

La arquitectura del sistema sigue el siguiente flujo de datos:

API Valenbisi → Apache NiFi → Apache Kafka → Apache Spark → PostgreSQL → Grafana



Cada componente cumple una función específica dentro del pipeline. Apache NiFi se encarga de la ingesta automática de datos desde la API, consultándola cada 2 minutos y publicando el resultado en Kafka. Apache Kafka actúa como sistema de mensajería, almacenando los mensajes en el topic "valenbisi" y desacoplando la ingesta del procesamiento. Apache Spark lee los mensajes de Kafka, parsea el JSON y calcula métricas sobre el estado de las estaciones. PostgreSQL almacena los datos procesados en una tabla relacional. Finalmente, Grafana se conecta a PostgreSQL y muestra los datos en un dashboard visual en tiempo real.


Toda la infraestructura se despliega mediante contenedores Docker, lo que facilita la portabilidad y la gestión de los servicios.

INGESTA DE DATOS – APACHE NIFI

Apache NiFi es una herramienta de integración de datos diseñada para automatizar el movimiento de datos entre sistemas. En este proyecto se ha utilizado para capturar los datos de la API de Valenbisi de forma periódica y publicarlos en Kafka.

El flujo de NiFi está compuesto por dos procesadores conectados en secuencia. El primero es InvokeHTTP, configurado para realizar peticiones GET a la URL <https://api.citybik.es/v2/networks/valenbisi> cada 2 minutos. El segundo es PublishKafka, que recibe el JSON de respuesta y lo publica en el topic "valenbisi" del broker de Kafka.

La conexión entre NiFi y Kafka se realiza mediante el Controller Service Kafka3ConnectionService, configurado con el bootstrap server 172.24.0.8:29092. Cada ejecución genera un mensaje JSON de aproximadamente 102 KB con los datos completos de todas las estaciones.




COLA DE MENSAJES – APACHE KAFKA

Apache Kafka es una plataforma de mensajería distribuida diseñada para el procesamiento de datos en tiempo real. En este proyecto actúa como intermediario entre NiFi y Spark, almacenando los mensajes publicados por NiFi hasta que Spark los consume.

Se ha creado el topic "valenbisi" con una partición y factor de replicación 1. El broker utilizado es la imagen oficial confluentinc/cp-kafka:7.3.3, desplegada en Docker. NiFi publica en el topic el JSON completo devuelto por la API, que contiene los datos de las 277 estaciones de Valenbisi en tiempo real.

Kafka garantiza que los mensajes no se pierdan aunque Spark no esté disponible en el momento de la publicación, ya que los almacena de forma persistente hasta que son consumidos.



The screenshot displays the Apache Kafka web interface for the 'valenbisi' topic. The interface includes a top navigation bar with 'Topics / valenbisi' and a 'Produce Message' button. Below this is a tabbed interface with 'Overview', 'Messages', 'Consumers', 'Settings', and 'Statistics'. The 'Overview' tab is active, showing a summary of the topic's configuration. A table below the summary lists the topic's metadata, including Partitions (1), Replication Factor (1), URP (0), In Sync Replicas (1 of 1), Type (External), Segment Size (103 KB), Segment Count (1), Clean Up Policy (DELETE), and Message Count (1). At the bottom, a table lists the partitions, showing one partition with ID 0, 1 replica, first offset 0, next offset 1, and a message count of 1.

Partitions	Replication Factor	URP	In Sync Replicas	Type
1	1	0	1 of 1	External

Segment Size	Segment Count	Clean Up Policy	Message Count
103 KB	1	DELETE	1

Partition ID	Replicas	First Offset	Next Offset	Message Count
0	1	0	1	1


ALMACENAMIENTO – POSTGRESQL

PostgreSQL es un sistema gestor de bases de datos relacional de código abierto. En este proyecto se utiliza para almacenar los datos procesados por Spark y servirlos a Grafana para su visualización.

Spark escribe los datos en la tabla `valenbisi_stations` mediante el driver JDBC de PostgreSQL. La tabla tiene el siguiente esquema:

- `id`: identificador único de la estación (texto)
- `name`: nombre de la estación (texto)
- `free_bikes`: número de bicis disponibles (entero)
- `empty_slots`: número de huecos libres (entero)
- `timestamp`: marca de tiempo de la última actualización (texto)

La tabla contiene 277 registros correspondientes a todas las estaciones de Valenbisi de Valencia. Los datos se sobrescriben en cada ejecución del script de Spark para mantener siempre los datos más recientes.



The screenshot shows a PostgreSQL query editor interface. On the left, a tree view displays the database structure, including the 'public' schema and the 'valenbisi_stations' table. The main area shows a query editor with the following SQL query:

```
SELECT * FROM public.valenbisi_stations
```

Below the query editor, the 'Salida de Datos' (Data Output) tab is active, displaying a table with the following columns and data:

id	name	free_bikes	empty_slots	timestamp
257	d0fc5e..._PLAZA AMERICA...	3	16	2026-05-19T1...
258	d1683f..._HOSPITAL_NUEVA...	1	39	2026-05-19T1...
259	d1f846..._CALLE_SALVADOR...	7	7	2026-05-19T1...
260	d2376..._CALLE_DEL_SALINAR	6	9	2026-05-19T1...
261	d3988f..._C/ MASQUEFA	15	0	2026-05-19T1...
262	d5cbe2..._AVDA_TRES_CRUCE...	6	14	2026-05-19T1...
263	d669b..._CALLE GRAN CANA...	6	9	2026-05-19T1...
264	d6775..._AVDA_AUSIAS_MAR...	5	10	2026-05-19T1...
265	d6a61..._AVDA_MANUEL_DE...	9	11	2026-05-19T1...
266	d7234..._C/ JAIME ROIG	1	18	2026-05-19T1...
267	d72cde..._AVDA DEL PUERTO	25	0	2026-05-19T1...
268	d81b7..._PLAZA_DE_LA_REI...	9	0	2026-05-19T1...
269	d8e50e..._SAN_VICENTE_DE...	0	15	2026-05-19T1...
270	d92f65..._AVDA DE BALEARE...	15	0	2026-05-19T1...
271	d9cdb..._PZA ALFONSO MA...	19	5	2026-05-19T1...
272	db04b..._AVDA BLASCO IBA...	18	2	2026-05-19T1...
273	db749..._FRANCISCO CUBEL...	16	0	2026-05-19T1...
274	dba0c1..._C/ DUQUE DE CALA...	6	2	2026-05-19T1...

VISUALIZACIÓN – GRAFANA

Grafana es una plataforma de visualización y monitorización de datos de código abierto. En este proyecto se conecta a PostgreSQL para mostrar los datos de Valenbisi en un dashboard interactivo con cuatro paneles.

El primer panel muestra un gráfico de barras con las 20 estaciones con mayor número de bicis disponibles, permitiendo identificar de un vistazo los puntos con mayor oferta de bicicletas en la ciudad.

El segundo panel muestra una tabla con todas las estaciones que tienen cero bicis disponibles, ordenadas por el número de huecos libres de forma descendente. Esto permite identificar las estaciones saturadas o con problemas de suministro.

El tercer panel muestra una tabla con las estaciones que no tienen huecos libres, es decir, las estaciones llenas donde no es posible devolver una bicicleta, ordenadas por número de bicis descendente.

El cuarto panel muestra tres indicadores KPI con las métricas generales del sistema: el total de estaciones (277), la media de bicis por estación (7.20) y el total de bicis disponibles en toda Valencia (1987).

